Inteligência Artificial

Outras estratégias de busca e Computação Evolutiva

Prof. Fabio Augusto Faria

Material adaptado de Profa. Ana Carolina Lorena e livro "Inteligência Artificial, S. Russell e P. Norving"

1º semestre 2015

Espaço de busca

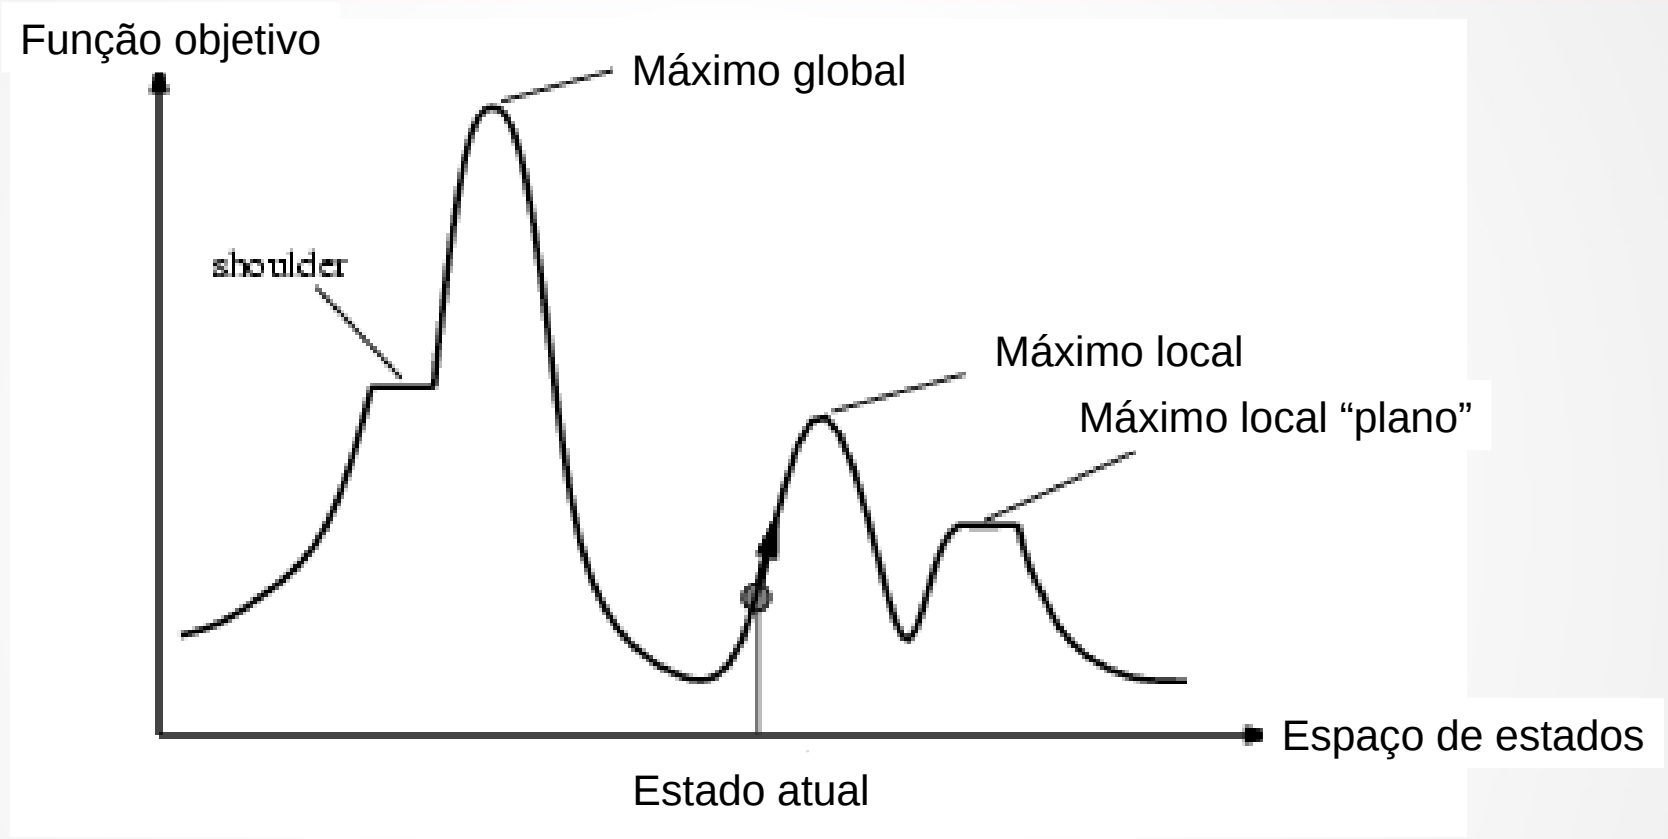

Algoritmo completo sempre encontra uma solução, caso ela exista

Algoritmo ótimo sempre encontra mínimo/máximo global

Busca subida em encosta

- **Máximos Locais**:
  - em contraste com *máximos globais*, são picos mais baixos do que o pico mais alto no espaço de estados (solução ótima)
  - a função de avaliação leva a um valor máximo para o caminho sendo percorrido: essa função utiliza informação local
  - porém, o nó final está em outro ponto mais alto
  - isto é uma consequência das decisões irrevogáveis do método
    - e.g., xadrez: eliminar a Rainha do adversário pode levar o jogador a perder

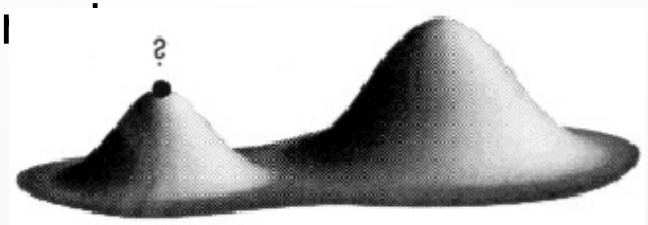

Busca subida em encosta

- **Platôs**:
  - uma região do espaço de estados onde a função de avaliação dá o mesmo resultado.

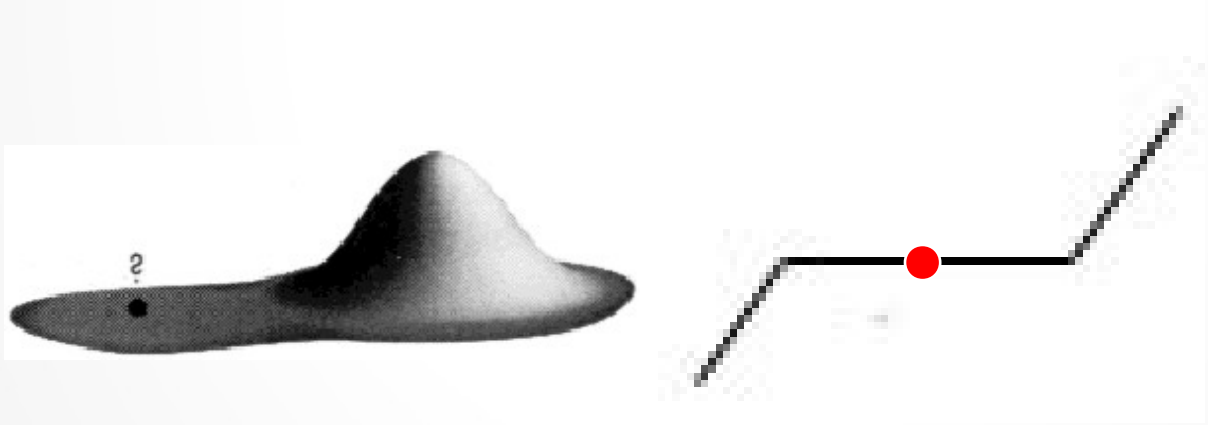

Busca subida em encosta

Mínimo local com h = 1

Todo sucessor tem custo mais alto

Alcançada em 5 passos a partir do estado inicial

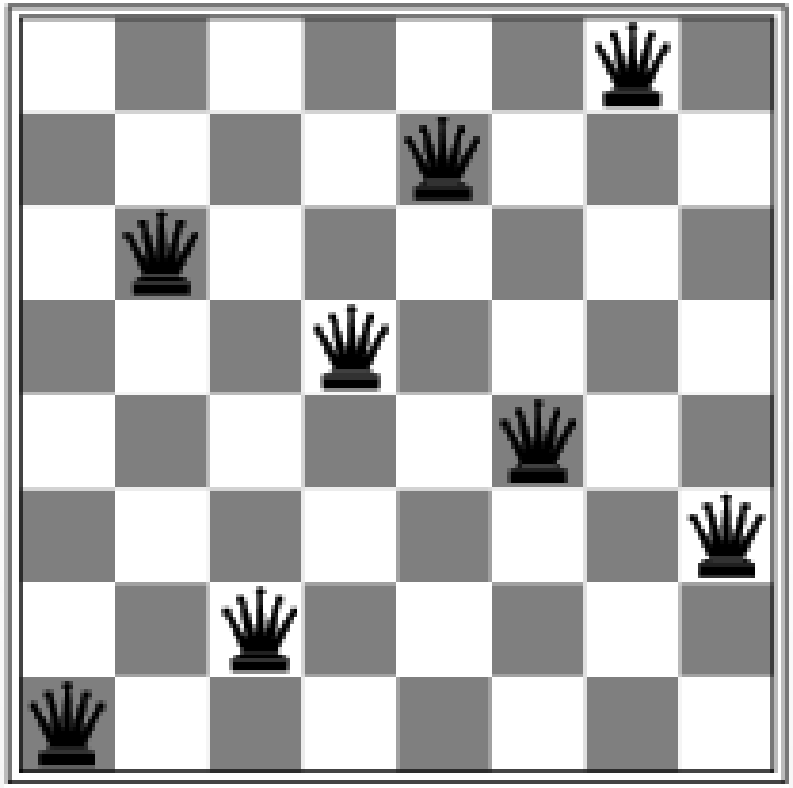

Busca subida em encosta

Problema das 8 rainhas

Estados iniciais aleatórios

- 86% das vezes busca fica paralisada
  - Resolve apenas 14% das instâncias do problema
- Mas é rápida
  - 4 passos em média quando tem sucesso
  - 3 passos em média quando fica paralisada
  - Em espaço que tem cerca de 17 milhões de estados

Busca subida em encosta

Mudar de estado em platôs

- Quando estados têm avaliações iguais
- Colocando um limite de vezes

Ex. Problema das 8 rainhas

- Com estados iniciais aleatórios, usando essa estratégia
  - Passa a resolver 94% das instâncias do problema
  - Mas demora mais
    - » 21 passos em média quando tem sucesso
    - » 64 passos em média quando falha

Busca de subida em encosta

Sucesso depende da topologia do espaço de estados

Se houver poucos máximos locais e platôs

- Subida de encosta com reinício aleatório encontrará boa solução com rapidez
- Mesmo para mais complexos, pode encontrar máximo local razoavelmente bom
  - Com poucos reinícios

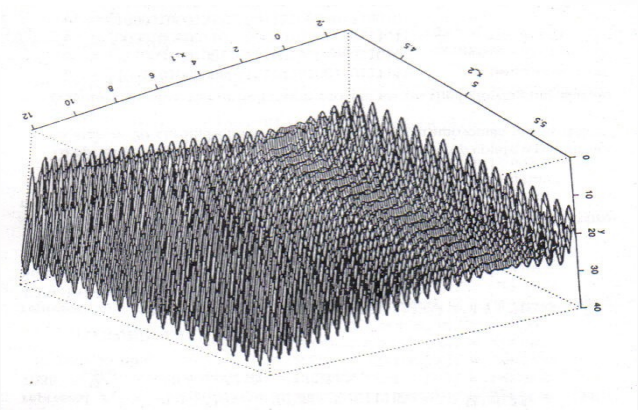

Têmpera Simulada

- Têmpera: esquentar o metal/vidro e depois esfriá-lo gradualmente
- Mudar a idéia de subida em encosta para **descida de gradiente**
- Uma bola rolando uma superfície acidentada e esta parará num **mínimo local**
- Para evitar, deve-se **agitar** a superfície para que a bola **saia** desse mínimo local

Têmpera Simulada

- A idéia desta estratégia é agitar com força no início e diminuir gradualmente a intensidade da **agitação**
  agitação == aleatoriedade

- Diferente da **subida em encosta** é que esta estratégia não escolhe o melhor estado sucessor, mas escolhe o melhor movimento **aleatório** (“agito”)

- Caso esse movimento aleatório não seja melhor, aceita-se um movimento com alguma probabilidade < 1 (vide Fig. 4.5)

- Exemplos: layout VLSI e escalonamentos.

Busca em Feixe Local

- Manter apenas 1 estado na memória é uma abordagem extrema para resolver problema de limitação de memória

- Esta estratégia mantém o controle de K estados, por vez

```
1- Inicia com K estados gerados aleatoriamente
2- Expande os sucessor de cada um dos K
3- Se objetivo, sucesso
4- Se não, seleciona os K melhores dentre todos os estados e volta para 1
```

Busca em Feixe Local

- Esses K reinícios aleatórios paralelos, os estados **se conversam** e tendem a abondonar caminhos infrutíferos
- Deslocando os recursos para o processo de **maior progresso**
- Problema está na **falta de diversidade** entre os K estados, se concentrando em uma pequena região do espaço de estados (Busca de subida de encosta)
- Solução é **Feixe Local Estocástico** que escolhe os K estados sucessores de forma **aleatória** considerando uma **probabilidade** maior que a atual (seleção natural)

Algoritmos Genéticos

Engloba métodos e técnicas computacionais inspirados:

- na teoria da evolução das espécies, de seleção natural (Darwin)
- na Genética iniciada por Mendel

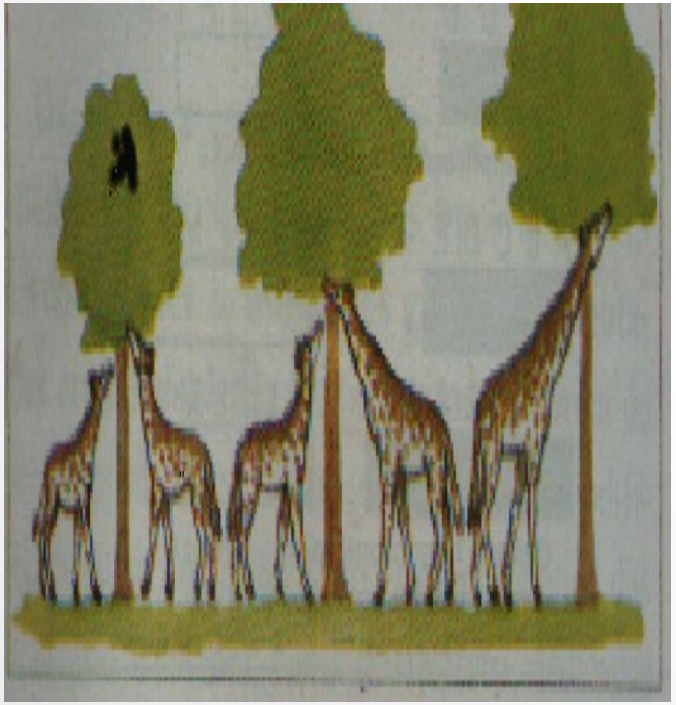

Bases da evolução:

- diversidade é gerada por cruzamento e mutações
- os seres mais adaptados ao seus ambientes sobrevivem
- as características genéticas de tais seres são herdadas pelas próximas gerações

Algoritmos Genéticos

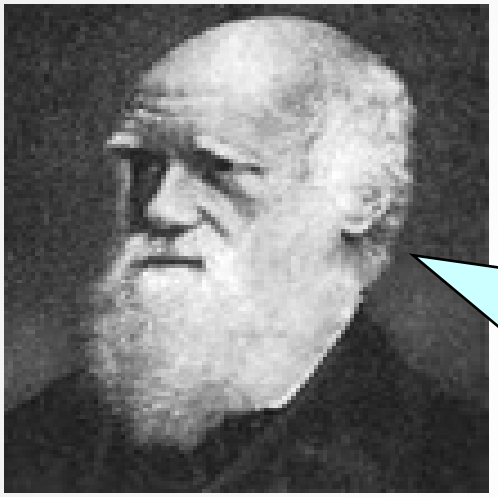

1859 - Charles Darwin publica o livro “A Origem das Espécies”

As espécies evoluem pelo princípio da seleção natural e sobrevivência do mais apto

Charles Darwin

1865 - Gregor Mendel apresenta experimentos do cruzamento genético de ervilhas

Pai da Genética

Gregor Mendel

Algoritmos Genéticos

Nos anos 1960 John Holland e seus alunos propuseram a construção de um algoritmo de busca e otimização: os algoritmos genéticos

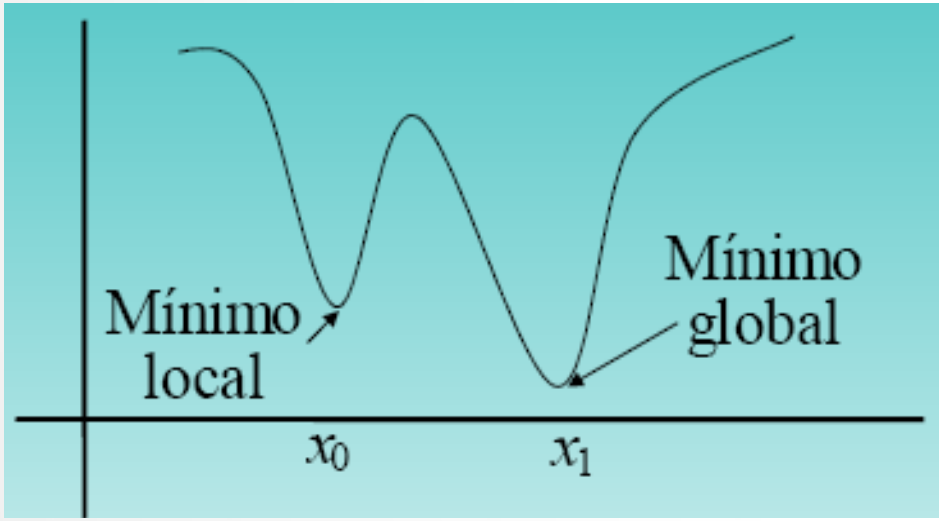

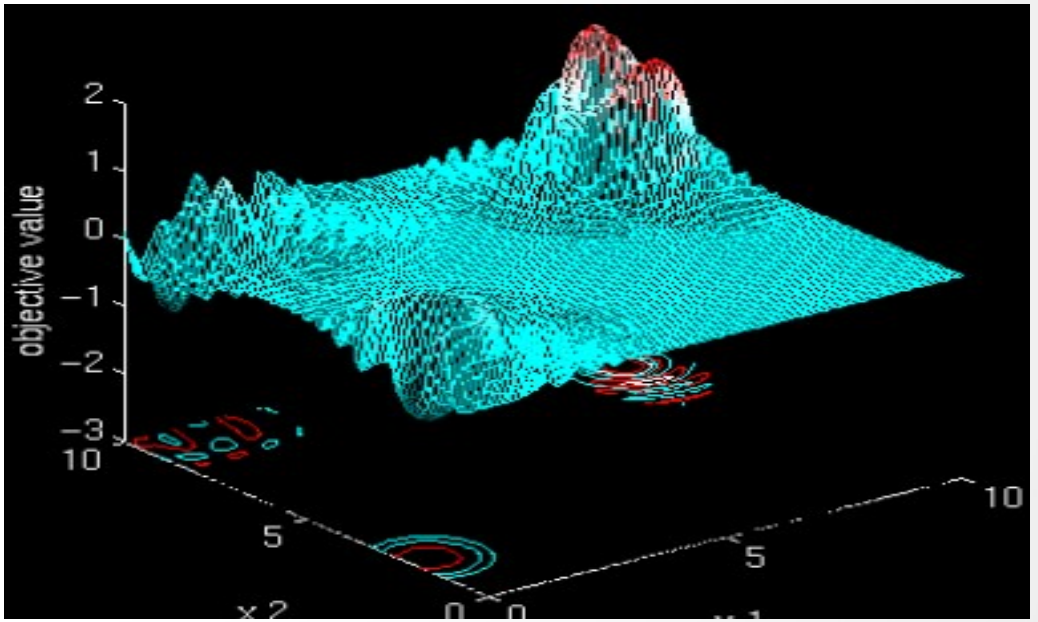

Algoritmos Genéticos

Os algoritmos genéticos usam como base, e procuram combinar:

- *A teoria da evolução das espécies* - a sobrevivência das estruturas/soluções mais adaptadas a um ambiente/problema

- *Estruturas genéticas* - utiliza a conceitos de hereditariedade e variabilidade genética para troca de informações entre as estruturas, visando a melhoria das mesmas

Algoritmos Genéticos

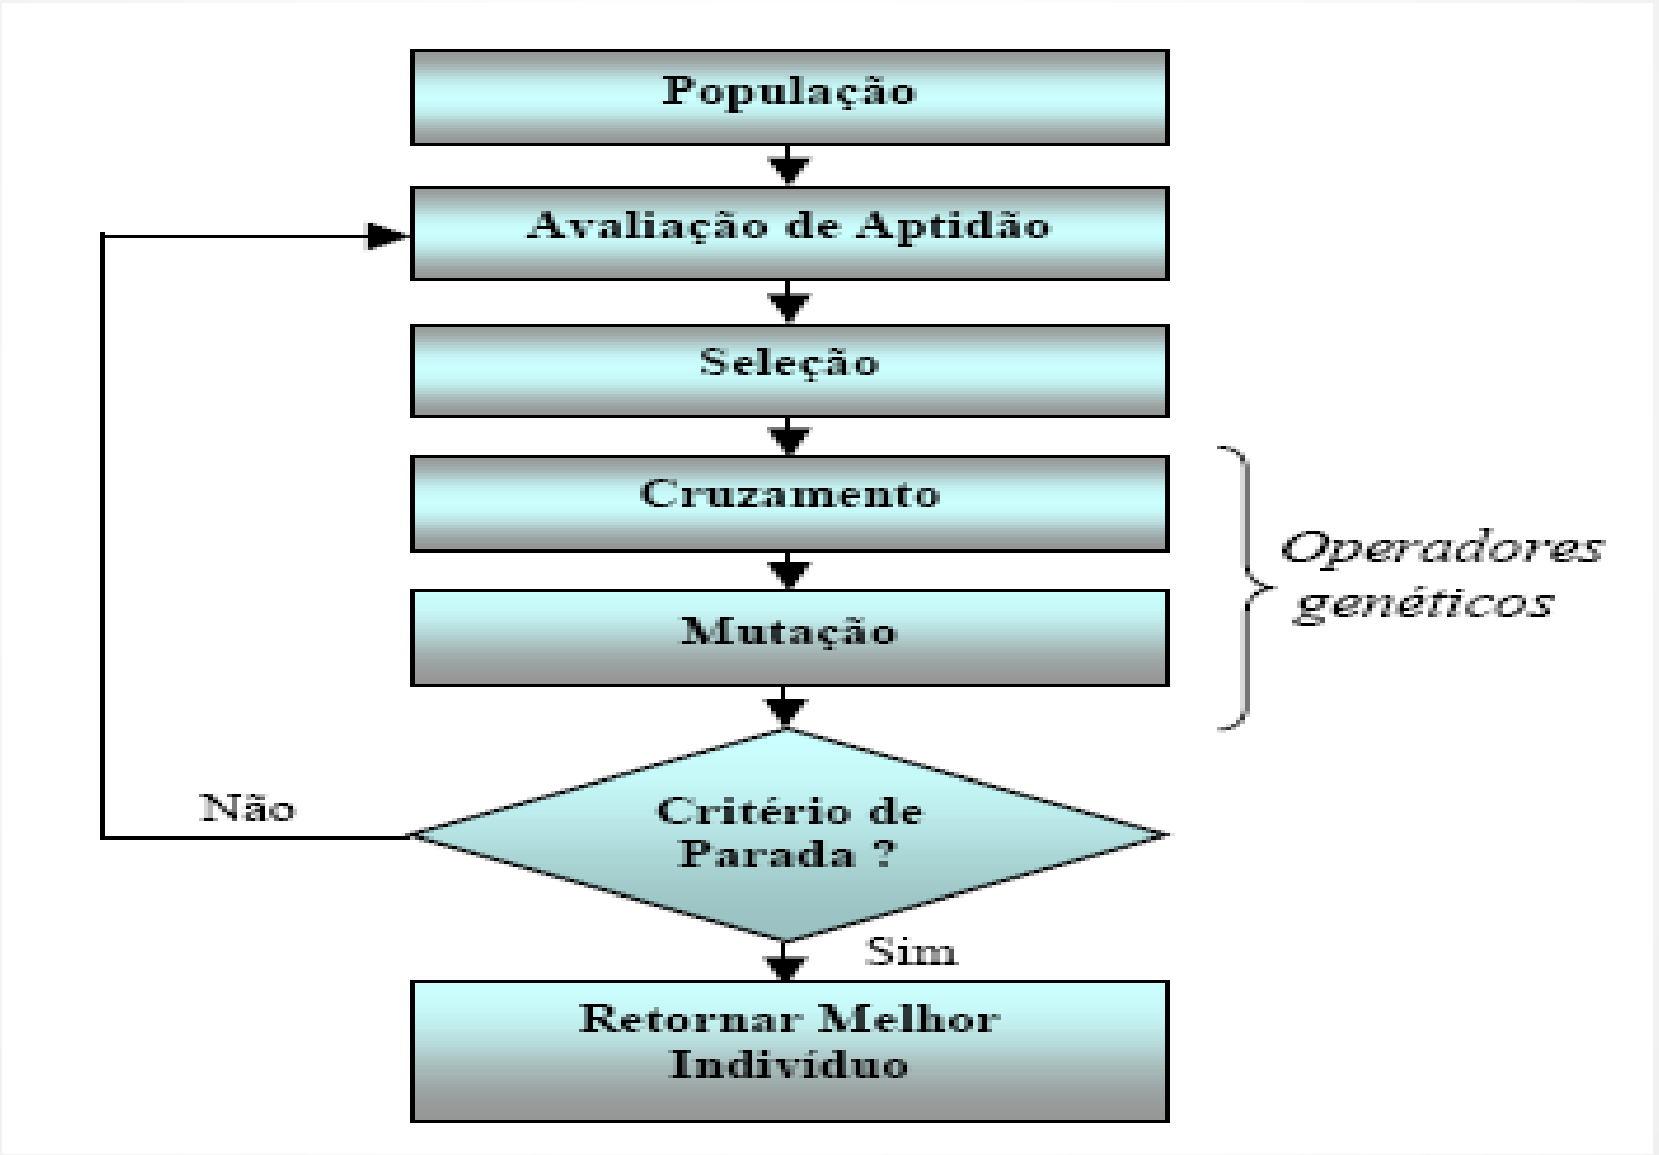

População

A população de um algoritmo genético é o conjunto de indivíduos que estão sendo cogitados como solução

Cada indivíduo é uma possível solução do problema

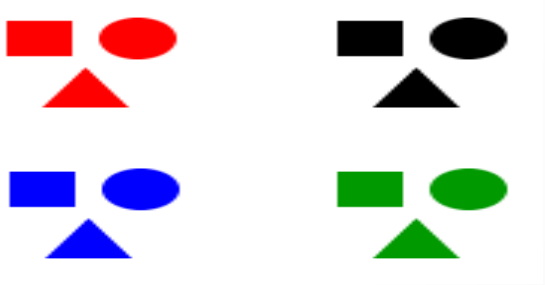

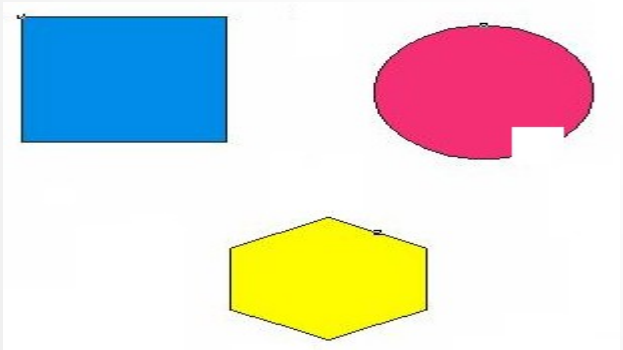

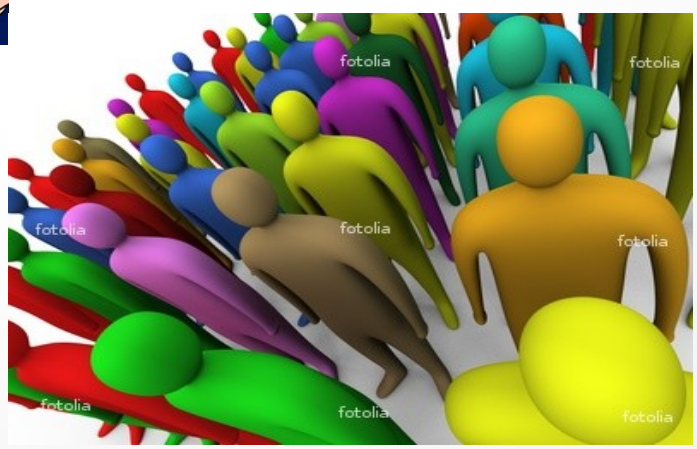

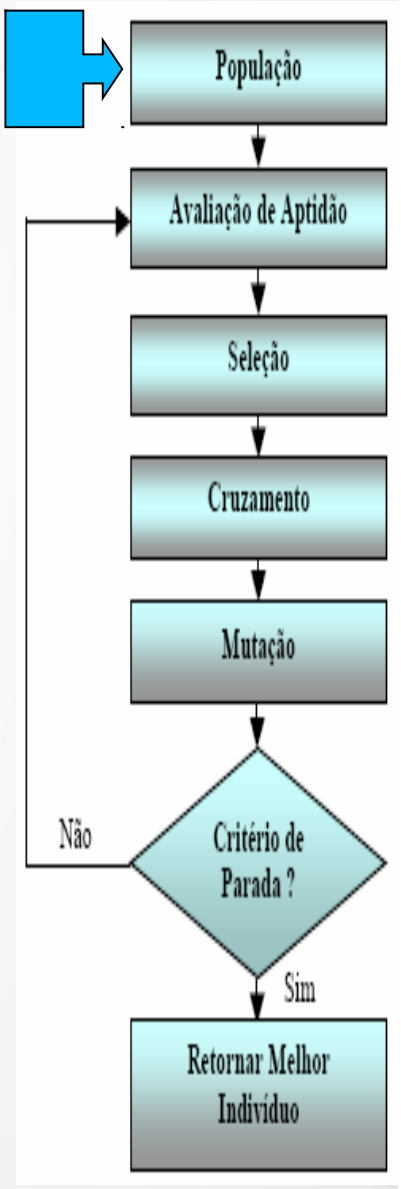

Indivíduo

Um indivíduo no AG é um cromossomo

Ou seja, um indivíduo é um conjunto de atributos da solução

Geralmente é uma cadeia de bits que representa uma solução possível para o problema

Outras representações são possíveis

Boa representação depende do problema

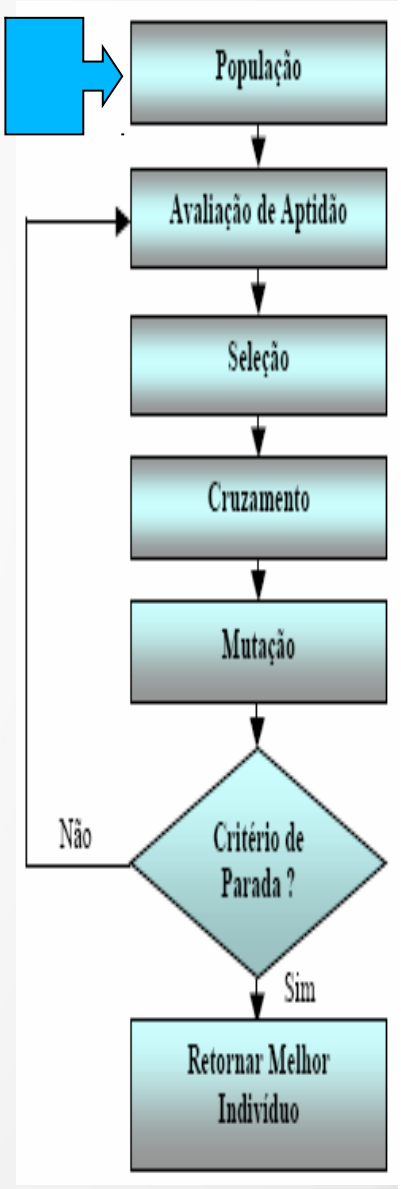

Exemplo: população de tamanho N=5
Geração de indivíduos, com seus cromossomos
Cada elemento do vetor é um gene, um atributo da solução

```
Indivíduo 1 = [1 1 1 0 1]
Indivíduo 2 = [0 1 1 0 1]
Indivíduo 3 = [0 0 1 1 0]
Indivíduo 4 = [1 0 0 1 1]
```

Função de aptidão

A função de avaliação, função de *fitness*, determina uma nota a cada indivíduo

Esta nota avalia quão boa é a solução que este indivíduo representa

Por exemplo, o objetivo de um AG pode ser maximizar o número de 1s

Indivíduos	Função de aptidão (*fitness*)
[11101]	4
[01101]	3
[00110]	2
[10011]	3
Aptidão média	3

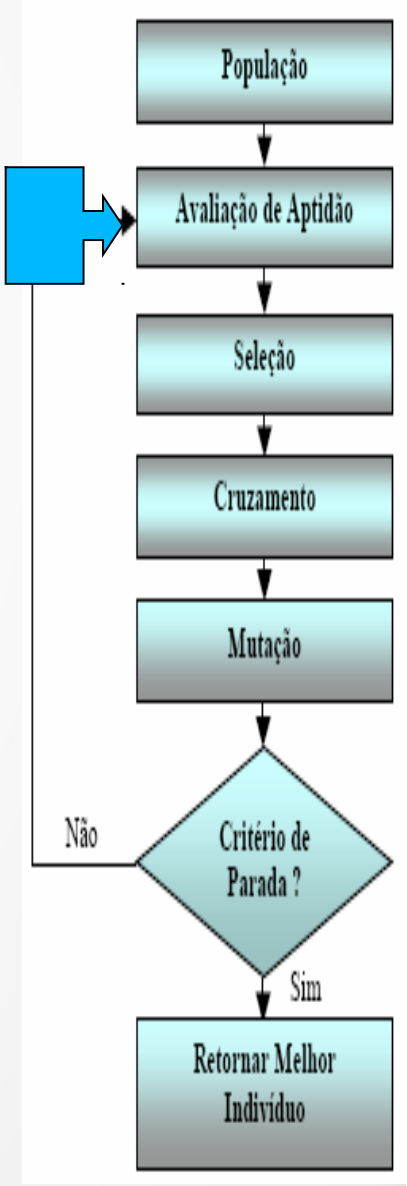

Seleção

De acordo com a teoria de Darwin, o melhor sobrevivente para criar a descendência é selecionado

Há muitos métodos para selecionar o melhor cromossomo

Dentre eles:

- Seleção por roleta
- Seleção por torneio

A seleção dirige o AG para as melhores regiões do espaço de busca

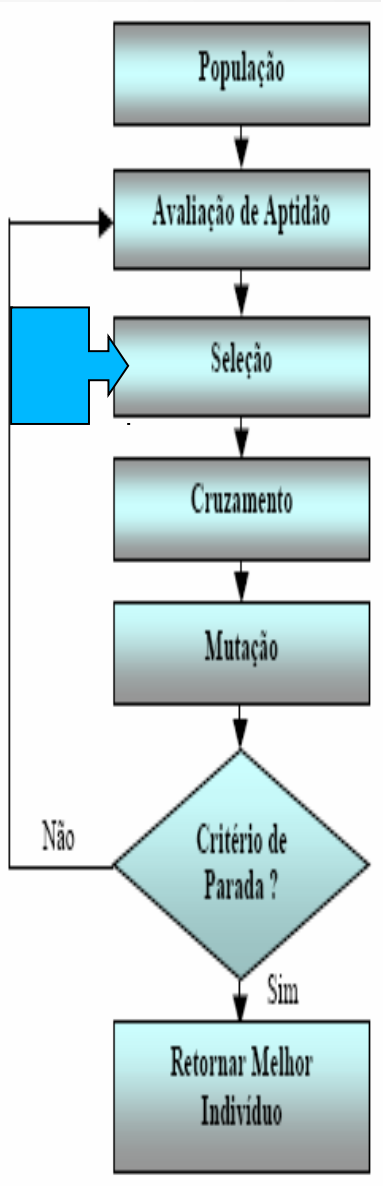

Seleção por roleta

Para visualizar este método considere um círculo dividido em N regiões (tamanho da população), onde a área de cada região é proporcional à aptidão do indivíduo

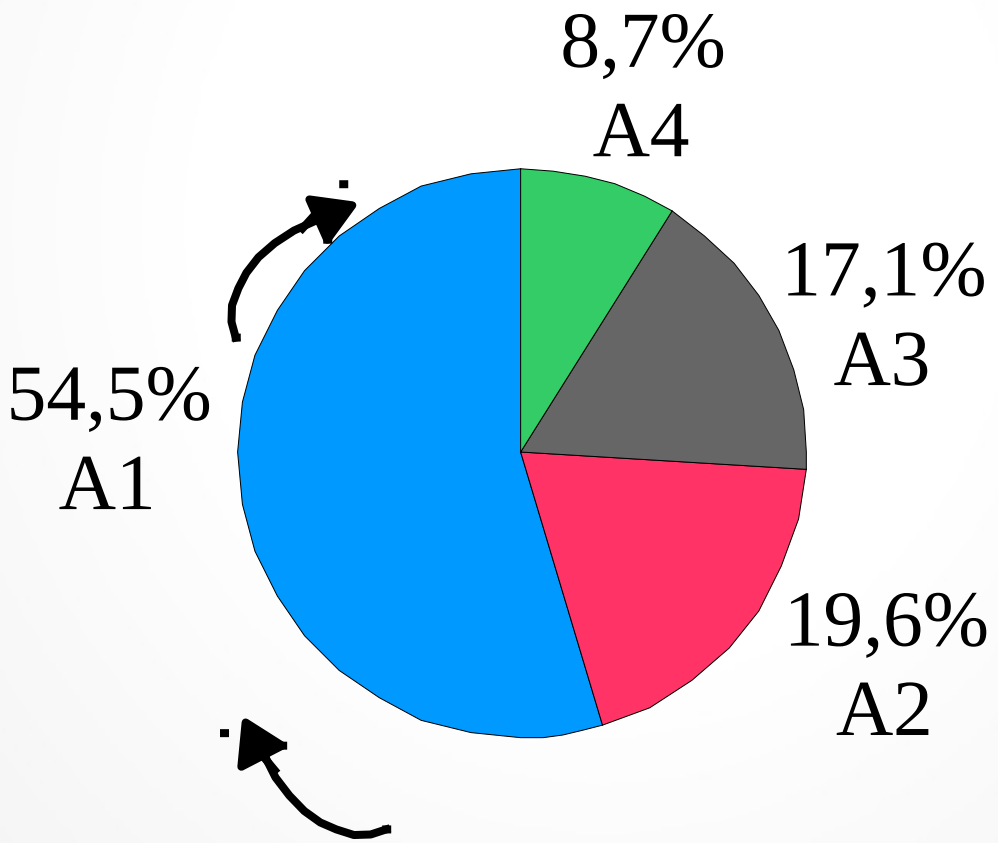

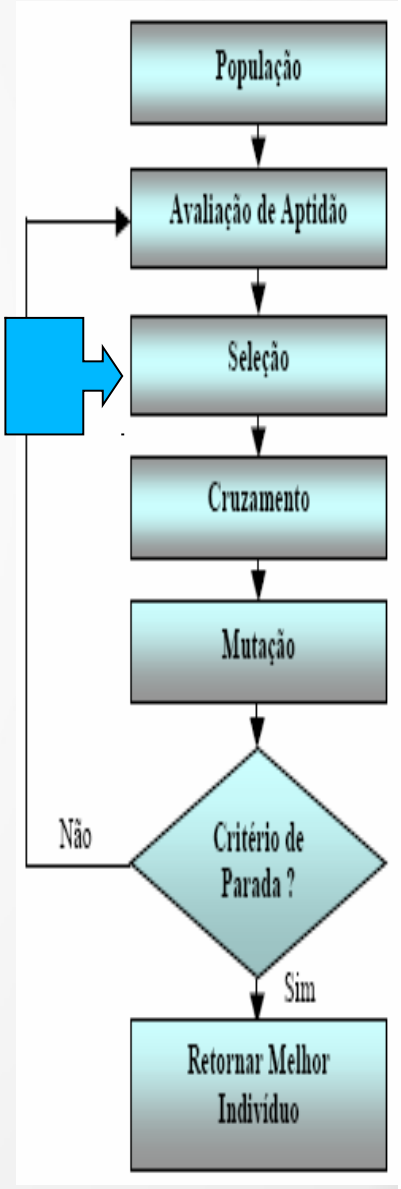

Seleção por roleta

Coloca-se sobre este círculo uma “roleta”

A roleta é girada um determinado número de vezes, dependendo do tamanho da população

São escolhidos como indivíduos que participarão da próxima geração, aqueles sorteados na roleta

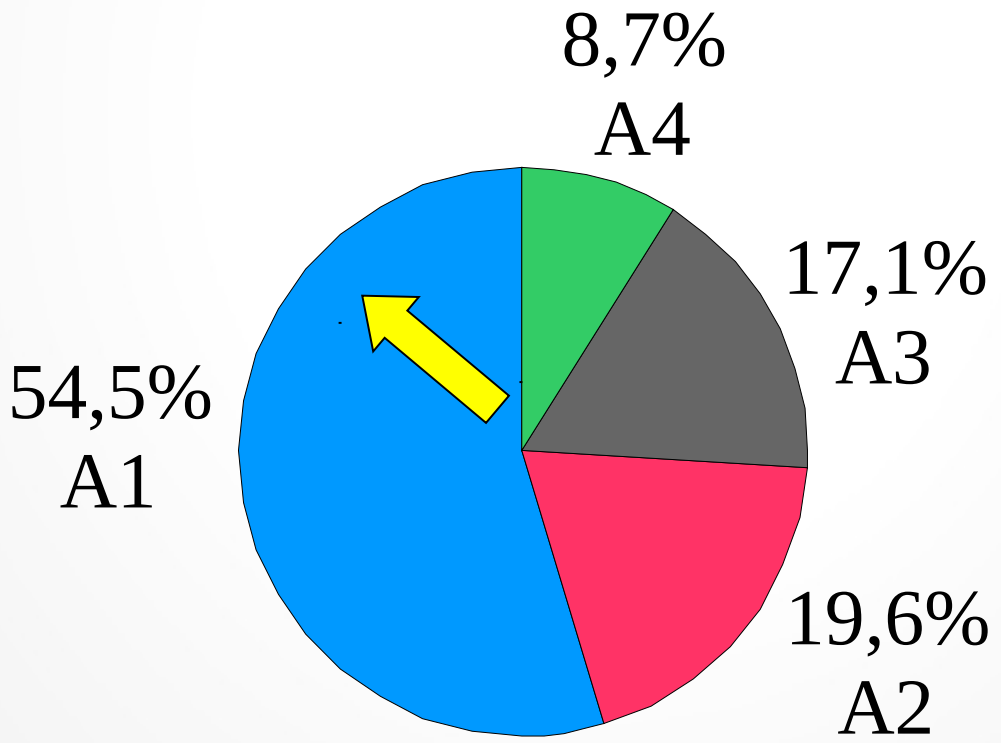

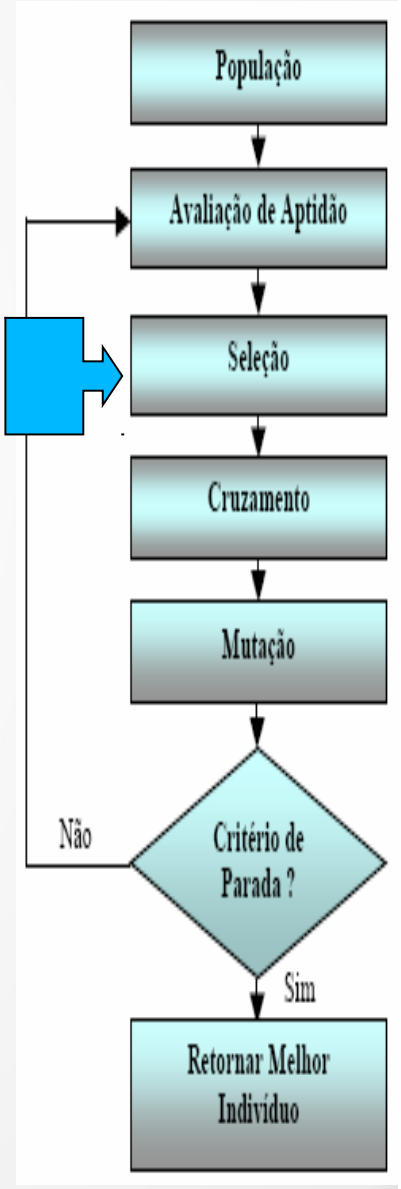

Operadores genéticos

Um conjunto de operações é necessário para que, dada uma população, se consiga gerar populações sucessivas que (espera-se) melhorem sua aptidão com o tempo

Estas operações são os **operadores genéticos**. São eles:

- **Cruzamento**
- **Mutação**

Os operadores genéticos permitem explorar áreas desconhecidas do espaço de busca

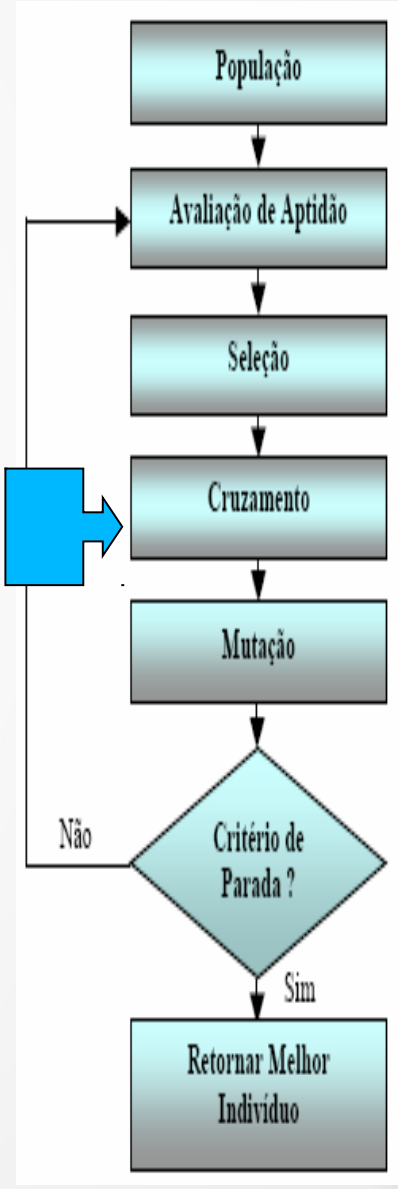

Cruzamento

O operador *crossover* (cruzamento) cria novos indivíduos, misturando características de **dois indivíduos pais**

O resultado desta operação é **um indivíduo** que potencialmente combine as melhores características dos indivíduos usados como base

Alguns tipos de cruzamento são:

- **Cruzamento em um ponto**
- **Cruzamento em dois pontos**

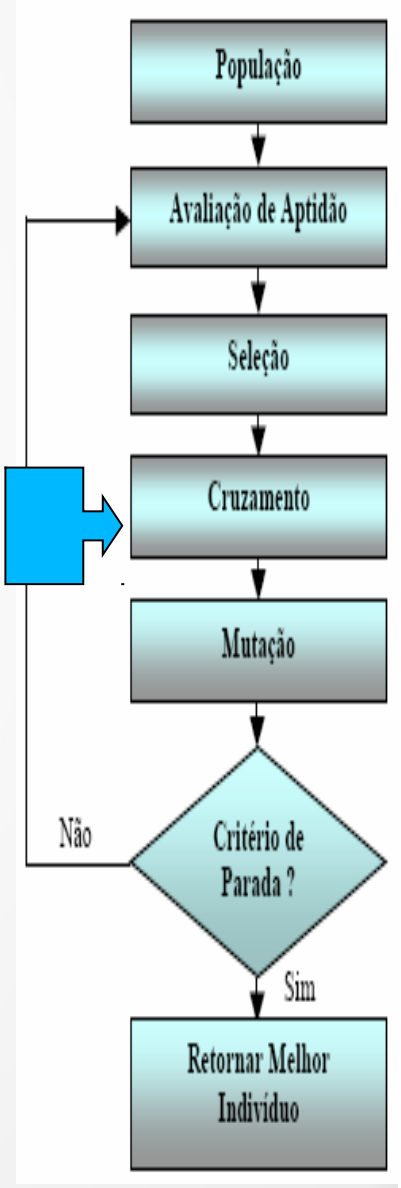

Cruzamento de um ponto

No cruzamento de um ponto divide-se cada progenitor em duas partes, em uma localidade k (escolhida aleatoriamente)

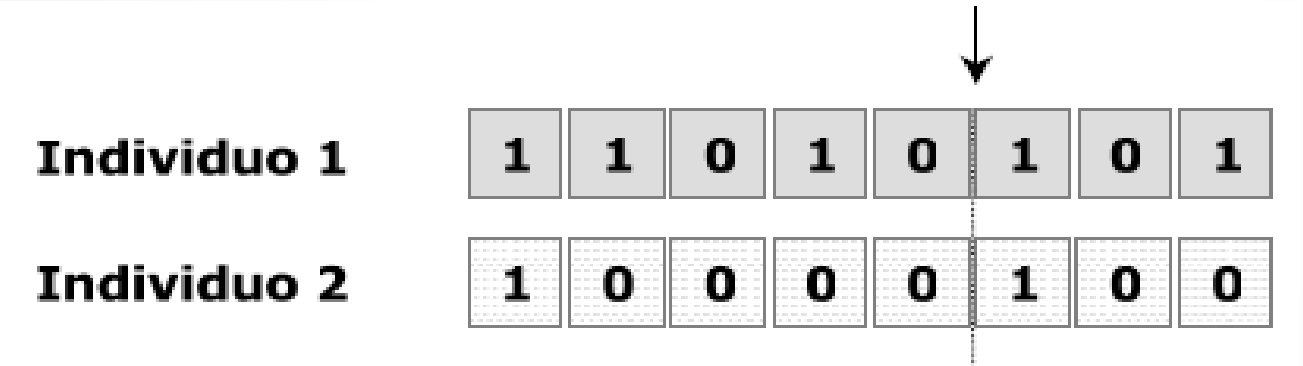

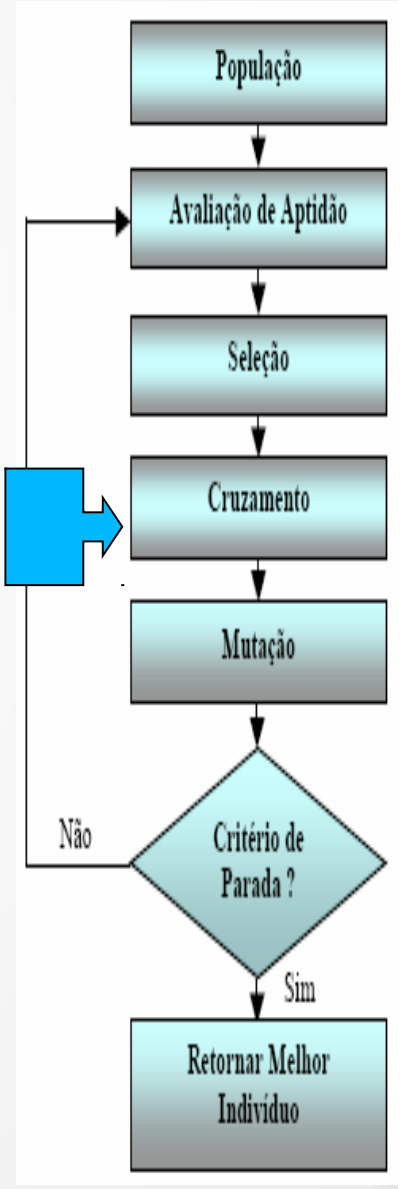

Cruzamento de um ponto

- O descendente 1 consiste em genes 1 a k-1 do progenitor 1, e genes k a n do progenitor 2
- O descendente 2 é “reverso”

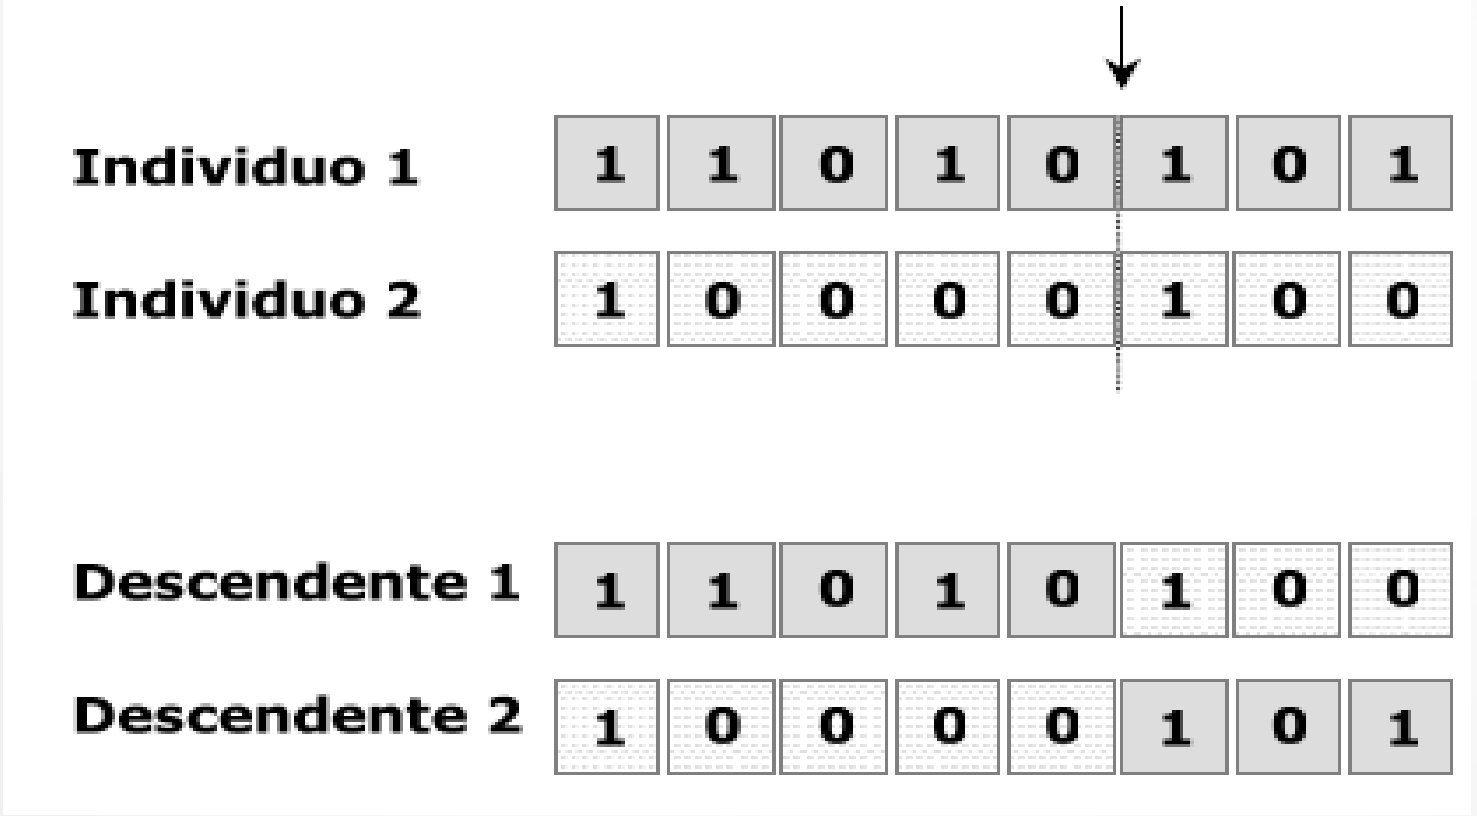

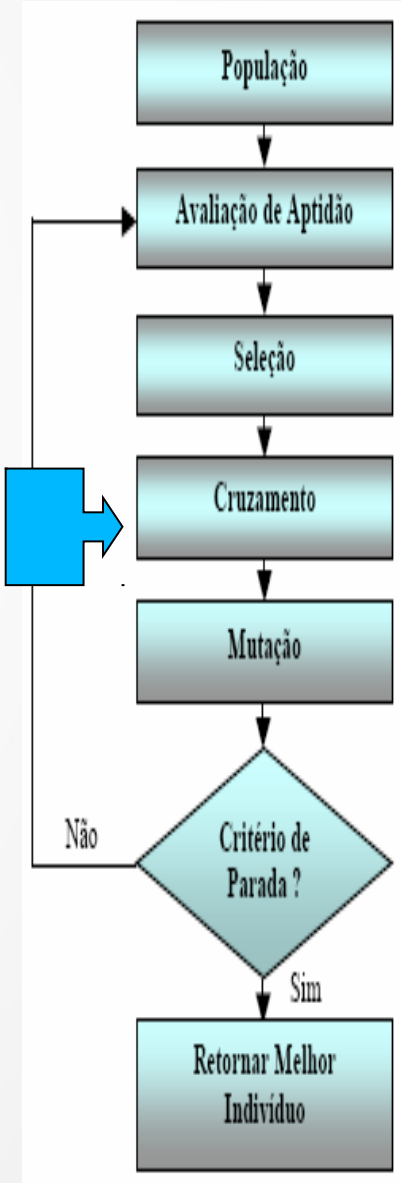

Mutação

A mutação modifica aleatoriamente alguma característica do indivíduo, sobre o qual é aplicada

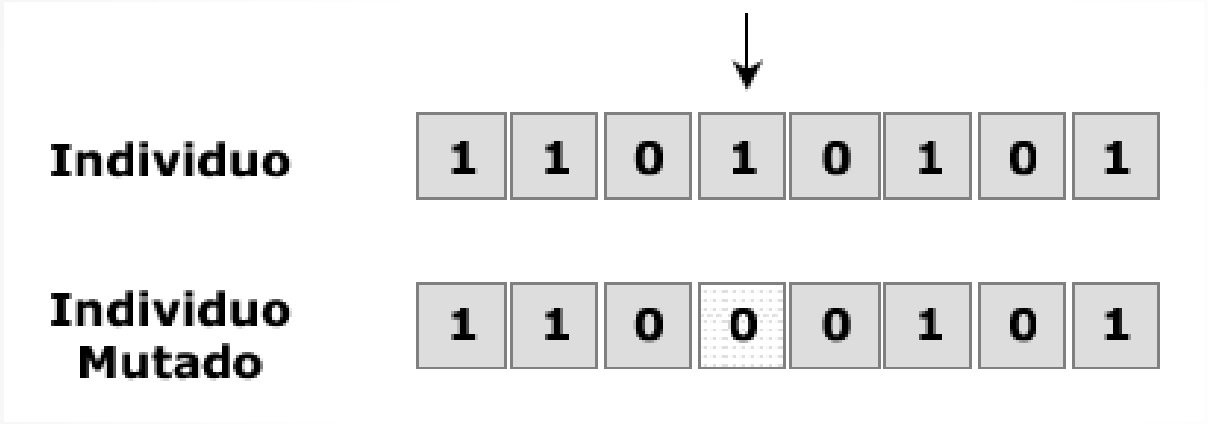

O operador de mutação é necessário para a introdução e manutenção da diversidade genética da população

Desta forma, a mutação assegura que a probabilidade de se chegar a qualquer ponto do espaço de busca, possivelmente, não será zero

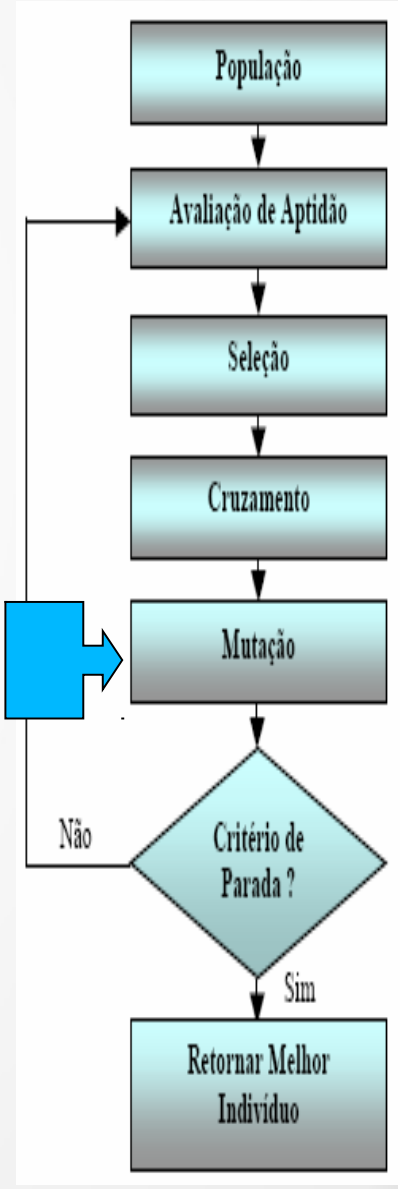

Gerações

Algoritmo é iterado até algum critério de parada

A cada passo, um novo conjunto de indivíduos é gerado a partir da população anterior

A este novo conjunto dá-se o nome de **geração**

Com a criação de uma grande quantidade de gerações que é possível obter resultados dos AGs

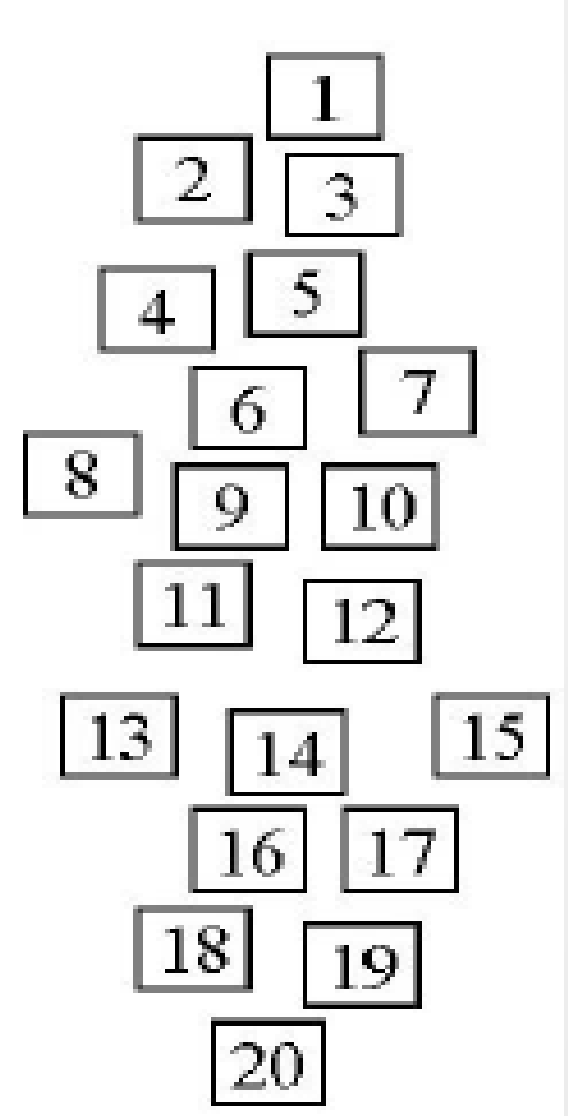

Algoritmo

Algoritmo_genético

- p = tamanho da população
- r = taxa de cruzamento
- m = taxa de mutação

Codificação e avaliação de aptidão são pontos chave

1. P← gerar aletoriamente *p* indivíduos
2. **Para cada** *i* em *P*, computar *Aptidão(i)*
3. **Enquanto** critério_parada não é atingido
   - 3.1 Selecionar *p* membros de *P* para reprodução
   - 3.2 Aplicar cruzamento a pares de indivíduos selecionados segundo taxa *r*, adicionando filhos em *PS*
   - 3.3 Realizar mutação em membros *PS*, segundo taxa *m*
   - *3.5* *P ← PS*
   - 3.6 **Para cada** *i* em *P*, computar *Aptidão(i)*
4. **Retornar** o indivíduo de *P* com maior aptidão

Exemplo

Codificando o problema

Ex.: problema 8 rainhas

- Cada estado deve especificar posição de 8 rainhas, em coluna com 8 quadrados
  - 8 x $\log_2 8$ = 24 bits se codificação binária

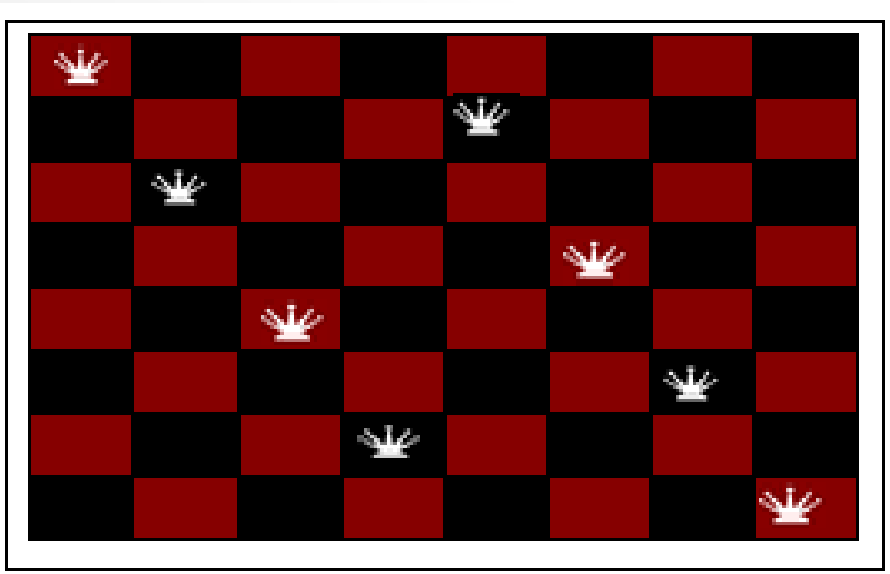

Binário = 111 101 011 001 110 100 010 000
Inteiro = 8 6 4 2 7 5 3 1

Exemplo

(a) Gerando população inicial

8 dígitos, com valores de 1 a 8

- Exemplo: população com 4 cadeias de 8 dígitos
  - Representam estados de 8 rainhas

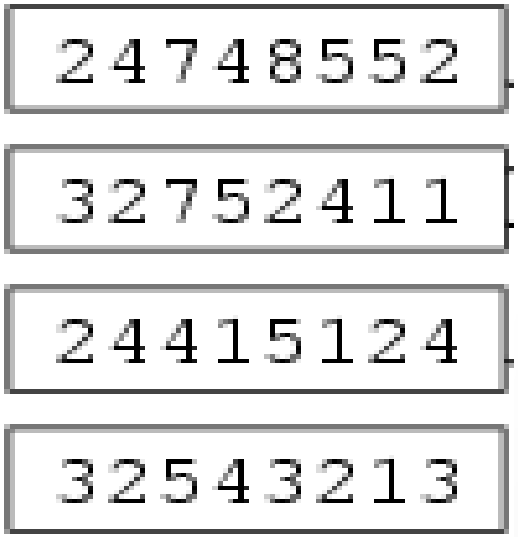

Exemplo

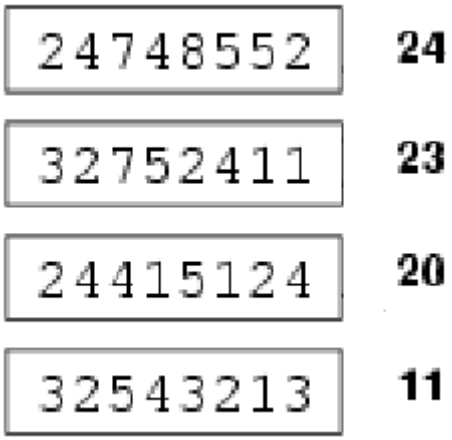

(b) *Avaliação*

Função de avaliação (aptidão)

- Deve retornar valores maiores para estados melhores
- Ex.: 8 rainhas: número de pares de rainhas não-atacantes
  - Valor 28 para uma solução
    - » (min = 0, max = 8 × 7/2 = 28)

Exemplo

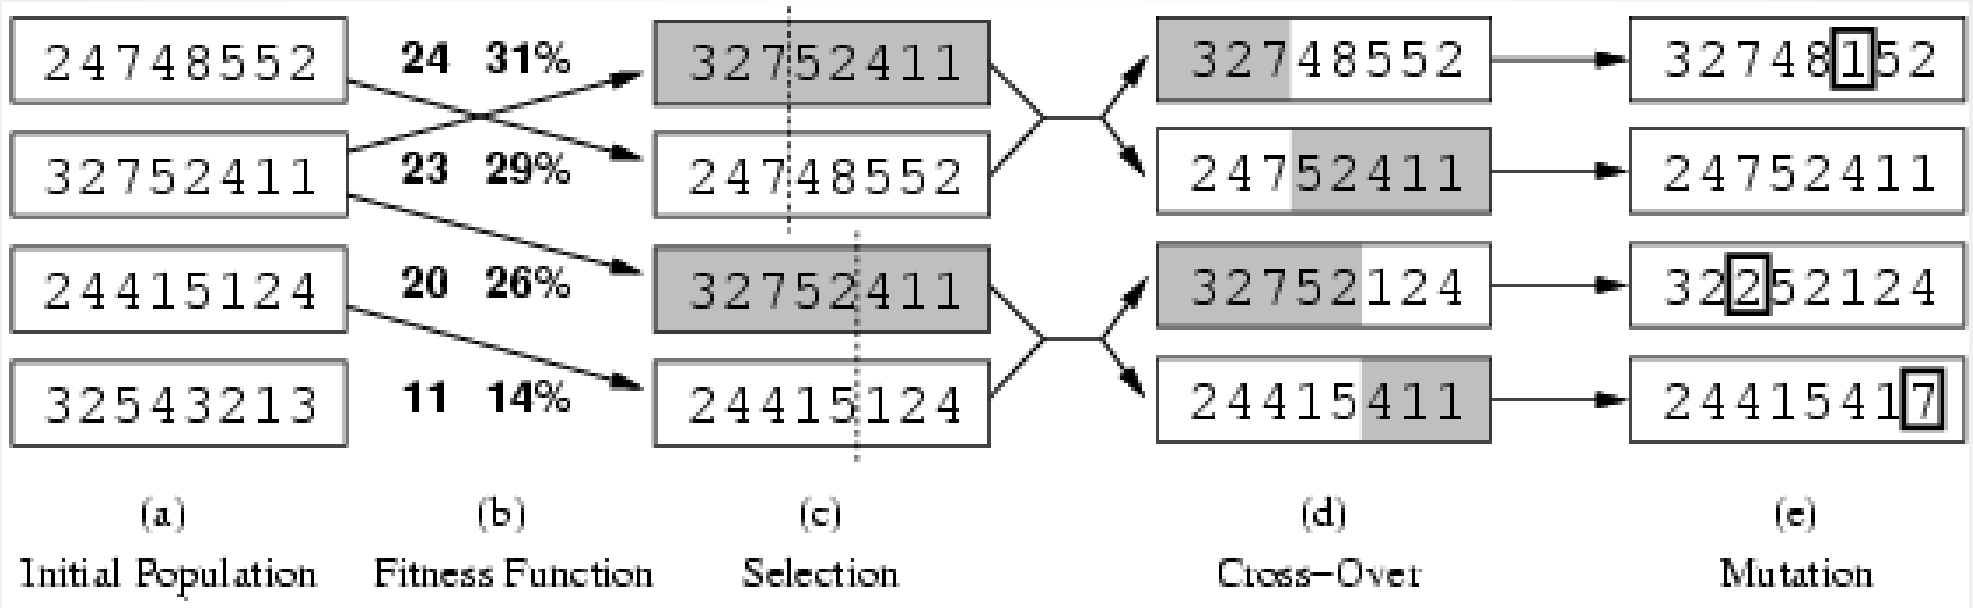

(c) *Seleção*

Proporcional à aptidão do indivíduo

- Vários métodos
- Todos tendem a privilegiar indivíduos mais aptos
  - 24/(24+23+20+11) = 31% no exemplo
  - 23/(24+23+20+11) = 29% etc

Cruzamento

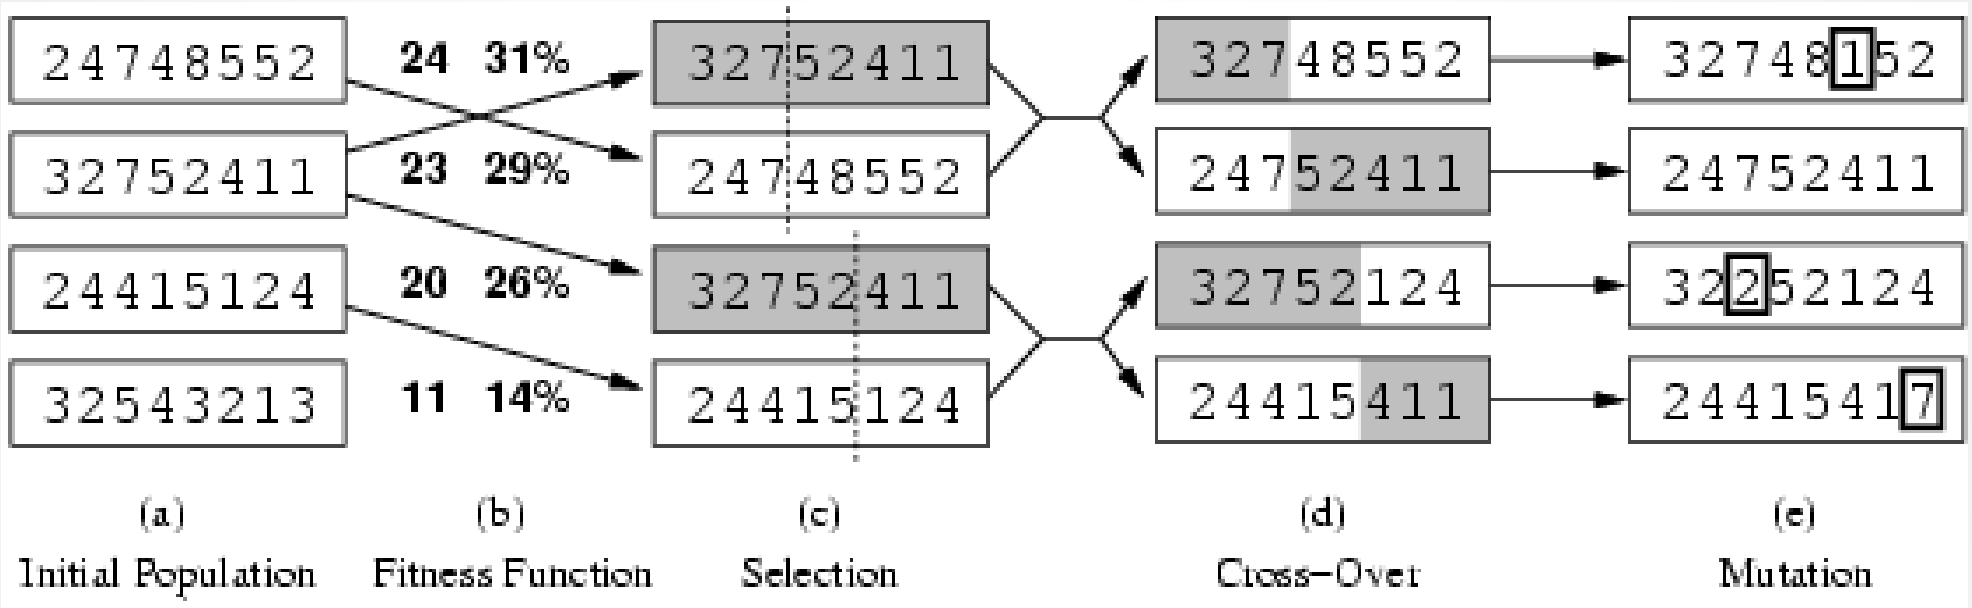

(d) *Cruzamento*

Indivíduos selecionados formam pares

Operador de cruzamento combina pares

- Ponto de cruzamento gerado ao acaso

Algoritmos Genéticos

Cruzamento

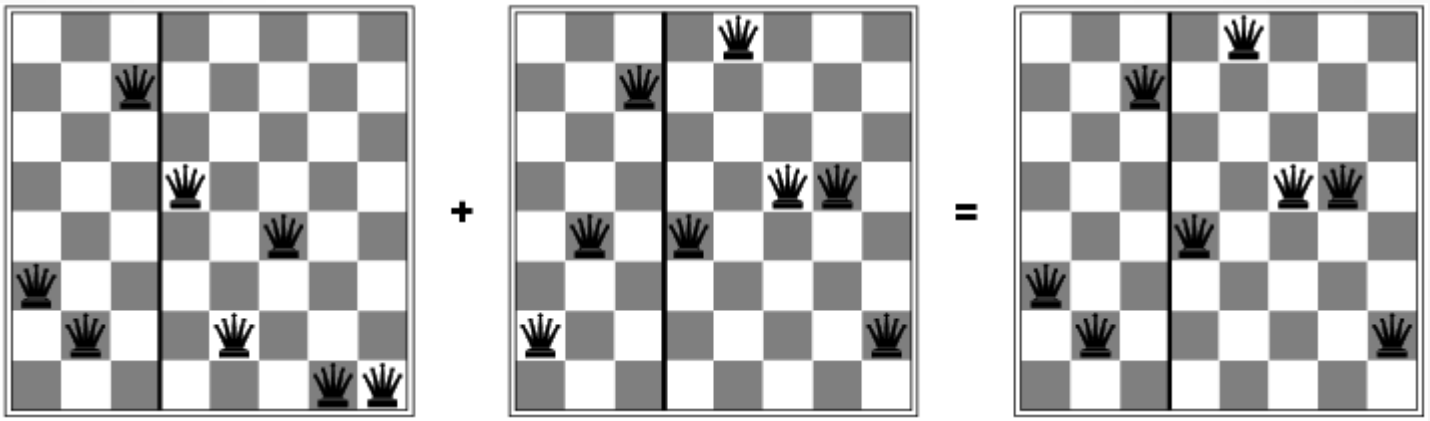

Algoritmos Genéticos

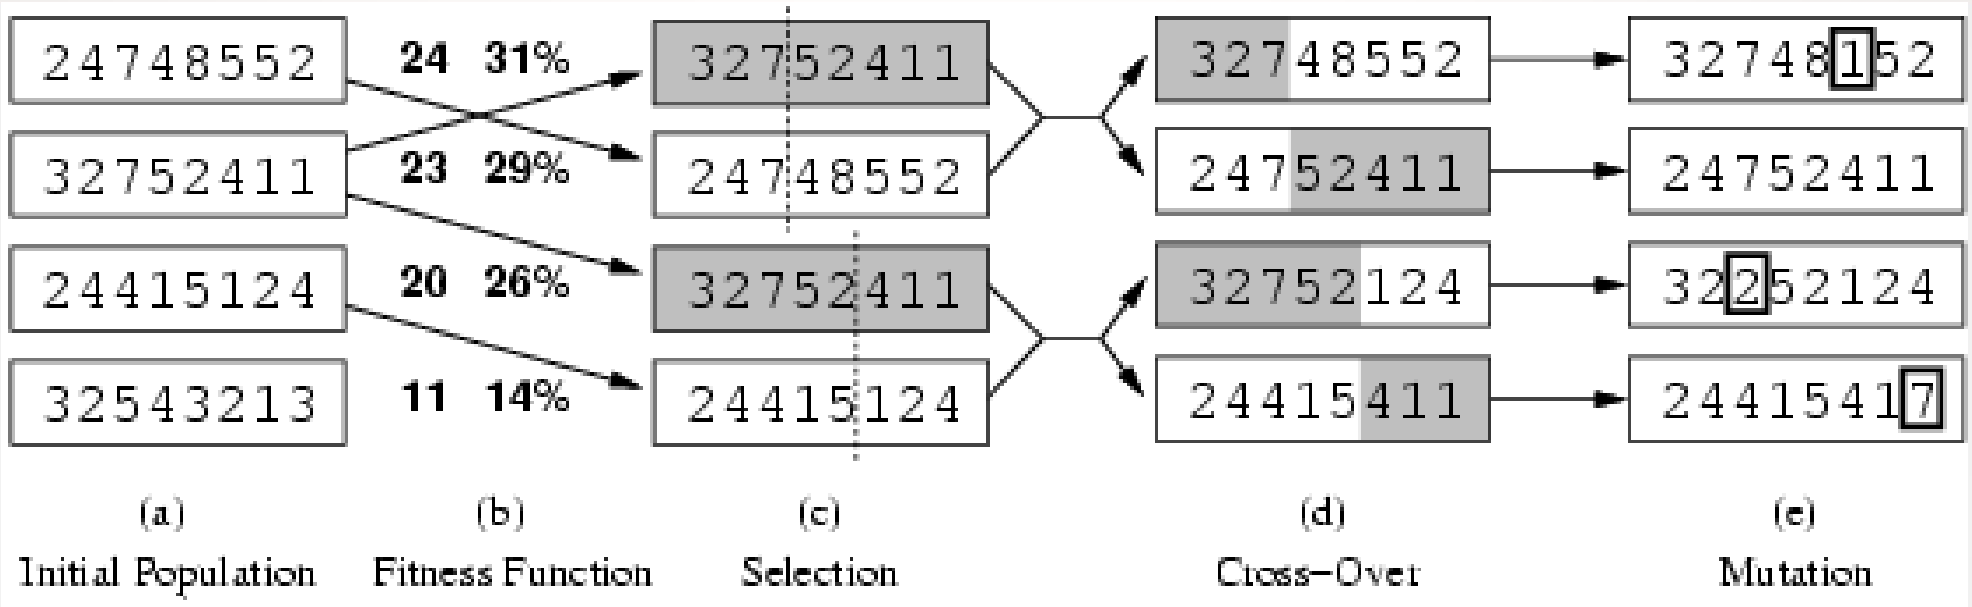

(e) *Mutação*

Mudança aleatória do valor de um gene

- Com pequena probabilidade

Introduz variações aleatórias

- Permitindo soluções pularem para diferentes partes do espaço de busca

Observações

- Se o AG estiver corretamente implementado, a população evolui em gerações sucessivas
- Aptidão do melhor indivíduo e do indivíduo médio aumentam em direção a um ótimo global

Trabalho Individual – 24/04/2015

- Implemente dois programa para resolver o problema das 8-rainhas, utilizando conceitos de: (1) Subida de Encosta; (2) Algoritmos Genéticos;
- O que entregar?

1) **Dois programas** (subida de encosta e algoritmo genético);

2) **Relatório comparativo** (e.g., tempo gasto para encontrar solução, # de falhas, # de reinícios, gerações de indivíduos, configuração de cada parâmetro, critérios adotados para resolver falhas, etc) entre os programas implementados.

Animação buscas

AG

http://math.hws.edu/xJava/GA/

http://www.obitko.com/tutorials/genetic-algorithms/example-function-minimum.php

http://www.obitko.com/tutorials/genetic-algorithms/example-3d-function.php

http://www.obitko.com/tutorials/genetic-algorithms/tsp-example.php

Referências

- Livros:
  - Russel e Norvig: Inteligência Artificial, cap 4

Programação Genética

- Extensão de Algoritmos Genéticos
- Indivíduos são programas

- Palestra sobre PG no Mundo Visual